


Projektstruktur – NVIDIA NeMo Framework zur Betrugserkennung von Telefonanrufen

Ziel

Die Projektstruktur dient als Grundlage für die Entwicklung einer KI-gestützten Betrugserkennung von Telefonanrufen bei einer Bank. Der Workflow orientiert sich am NVIDIA NeMo Framework und umfasst den vollständigen Machine-Learning-Lebenszyklus von der Datenaufbereitung bis zum Monitoring eines trainierten Modells.

Ordner	Beschreibung
notebooks/	Enthält alle Jupyter Notebooks. Die Notebooks bilden den gesamten Workflow ab – von der Datenaufnahme über NeMo Curator, NeMo Customizer und NeMo Evaluator bis hin zum Monitoring. Sie dienen als zentrale Entwicklungs- und Experimentierumgebung.
data/	Ablage aller Datensätze. Enthält Rohdaten (Telefontranskripte), bereinigte Daten, kuratierte Datensätze, SFT-Trainingsdaten sowie Evaluationsdatensätze. Dadurch bleibt der gesamte Datenlebenszyklus nachvollziehbar.
configs/	Zentrale Konfigurationsdateien (YAML) für NeMo Curator, Customizer, Evaluator, Weights & Biases sowie Prometheus. Parameter werden nicht in den Notebooks, sondern in Konfigurationsdateien gepflegt, um Wiederholbarkeit und Vergleichbarkeit sicherzustellen.
models/	Speicherung der verwendeten Foundation Models, der während des Fine-Tunings erzeugten Checkpoints (LoRA/QLoRA) sowie der freigegebenen Produktionsmodelle.
wandb/	Lokale Ablage für Weights & Biases. Enthält Informationen zu Experimenten, Artefakten, Trainingsläufen und Protokollen. Die eigentliche Verwaltung der Experimente erfolgt über die W&B-Plattform.
monitoring/	Konfigurationen für Prometheus und Grafana. Hier werden Infrastruktur- und Modellmetriken gesammelt und Dashboards zur Überwachung der Lösung abgelegt.
src/	Wiederverwendbarer Python-Code. Enthält Funktionen für Datenbereinigung, Deduplizierung, Modelltraining, Evaluation und Monitoring, die von den Jupyter Notebooks aufgerufen werden.
reports/	Automatisch erzeugte Berichte wie Datensatzanalysen, Evaluationsberichte und Audit-Reports. Diese dienen der Dokumentation und Nachvollziehbarkeit der Projektergebnisse.

Projektworkflow



Vorteile der Struktur

- Klare Trennung zwischen Daten, Code, Konfigurationen und Modellen.
- Vollständige Nachvollziehbarkeit des Daten- und Modelllebenszyklus.
- Reproduzierbare Experimente durch zentrale Konfigurationen.
- Unterstützung des vollständigen NVIDIA NeMo Workflows (Curator → Customizer → Evaluator).
- Integration von Weights & Biases für Experiment-Tracking und Artefaktverwaltung.
- Einsatz von Prometheus und Grafana zur Überwachung von Infrastruktur und Modellbetrieb.
- Skalierbare Struktur, geeignet für Proof-of-Concepts sowie für den Übergang in produktionsnahe ML- und MLOps-Umgebungen.